
Предисловие

Я исключительно горжусь первым изданием книги "Наука о данных с нуля". Книга оказалась именно такой, какой я и хотел ее видеть. Но несколько лет развития науки о данных, прогресса в экосистеме Python и личного роста как разработчика и педагога изменили мои представления о том, как первая книга по науке о данных должна выглядеть.

В жизни не бывает повторных попыток. Однако в книжном деле существуют вторые издания. И поэтому я переписал весь исходный код и примеры, используя Python 3.6 (и многие из его новых функций, таких как аннотации типов). Я вплет в книгу акцент на написании чистого кода. Я заменил некоторые игрушечные примеры первого издания более реалистичными, используя "реальные" наборы данных. Я добавил новые материалы по таким темам, как глубокое обучение, статистика и обработка естественного языка, соответствующие проблемам, которые, вероятно, придется решать современным исследователям. (Я также удалил некоторые материалы, которые кажутся менее субъективными.) И я прошелся по книге мелкозубой расческой, исправляя ошибки, переписывая объяснения, которые были не очень понятны, и по ходу освежая некоторые шутки.

Первое издание было замечательной книгой, но это издание еще лучше. Наслаждайтесь!

Условные обозначения, принятые в книге

В книге используются следующие типографические условные обозначения:

- ◆ *курсив* указывает на новые термины;
- ◆ моноширинный шрифт используется для листингов программ, а также внутри абзацев для ссылки на элементы программ, такие как переменные или имена функций, базы данных, типы данных, переменные окружающей среды, операторы и ключевые слова;
- ◆ ~~жирный моноширинный шрифт~~ показывает команды либо другой текст, который должен быть напечатан пользователем, а также ключевые слова в коде;
- ◆ моноширинный шрифт курсивом показывает текст, который должен быть заменен значениями пользователя либо значениями, определяемыми по контексту.



Данный элемент обозначает подсказку или совет.



Данный элемент обозначает общее замечание.



Данный элемент обозначает предупреждение или предостережение.

Использование примеров кода

Дополнительный материал (примеры кода, упражнения и пр.) доступны для скачивания по адресу <https://github.com/joelgrus/data-science-from-scratch>.

Эта книга предназначена для того, чтобы помочь вам решить ваши задачи. В целом, если код примеров предлагается вместе с книгой, то вы можете использовать его в своих программах и документации. Вам не нужно связываться с нами с просьбой о разрешении, если вы не воспроизводите значительную часть кода. Например, написание программы, которая использует несколько фрагментов кода из данной книги, официального разрешения не требует.

Адаптированный вариант примеров в виде электронного архива вы можете скачать по ссылке <ftp://ftp.bhv.ru/9785977567312.zip>. Эта ссылка доступна также со страницы книги на веб-сайте www.bhv.ru.

Благодарности

Прежде всего, хотел бы поблагодарить Майка Лукидеса (Mike Loukides) за то, что принял мое предложение по поводу этой книги и настоял на том, чтобы я довел ее до разумного объема. Он мог бы легко сказать: "Кто этот человек, вообще, который шлет мне образцы глав, и как заставить его прекратить, наконец?" И я признателен, что он этого не сделал. Хотел бы поблагодарить моего редактора, Мари Богуро (Marie Beaugureau), которая консультировала меня в течение всей процедуры публикации и привела книгу в гораздо более удобоваримый вид, чем если бы этим я занимался сам.

Я бы не написал эту книгу, если бы не изучил науку о данных, и, возможно, я бы не научился ей, если бы не влияние Дэйва Хсу (Dave Hsu), Игоря Татарина (Igor Tatarinov), Джона Раузера (John Rauser) и остальной группы единомышленников из Farecast (это было так давно, что в то время даже не было понятия науки о данных). Хорошие парни в Coursera также заслуживают много добрых слов.

Я также благодарен моим бета-читателям и рецензентам. Джэй Фандлинг (Jay Fundling) обнаружил тонны ошибок и указал на многие нечеткие объяснения,

и в итоге книга оказалась намного лучше и корректней благодаря ему. Дэбаши Гош (Debashis Ghosh) героически провела санитарную проверку моих статистических выкладок. Эндрю Массельман (Andrew Musselman) предложил смягчить первоначальный аспект книги, касающийся утверждения, что "люди, предпочитающие язык R вместо Python, есть моральные извращенцы", что, думаю, в итоге оказалось неплохим советом. Трэй Кози (Trey Causey), Райан Мэттью Балфанц (Ryan Matthew Balfanz), Лорис Муларони (Loris Mularoni), Нуриа Пуджол (Núria Pujol), Роб Джефферсон (Rob Jefferson), Мэри Пэт Кэмпбелл (Mary Pat Campbell), Зак Джири (Zach Geary) и Венди Грас (Wendy Grus) также высказали неоценимые замечания. За любые оставшиеся ошибки, конечно же, отвечаю только я.

Я многим обязан сообществу с хештегом **#datascience** в Twitter за то, что его участники продемонстрировали мне массу новых концепций, познакомили меня со множеством замечательных людей и заставили почувствовать себя двоечником, да так, что я ушел и написал книгу в качестве противовеса. Особые благодарности снова Трэйу Кози (Trey Causey) за то, что нечаянно упомянул, чтобы я включил главу про линейную алгебру, и Шин Дж. Тэйлор (Sean J. Taylor) за то, что неумышленно указала на пару больших несоответствий в *главе "Работа с данными"*.

Но больше всего я задолжал огромную благодарность Ганге (Ganga) и Мэдлин (Madeline). Единственная вещь, которая труднее написания книги, — это жить рядом с тем, кто пишет книгу, и я бы не смог ее закончить без их поддержки.

Предисловие к первому изданию

Наука о данных

Исследователей данных называют "самой сексуальной профессией XXI века"¹. Очевидно, тот, кто так выразился, никогда не бывал в пожарной части. Тем не менее наука о данных — это действительно передовая и быстроразвивающаяся отрасль знаний, и не придется рыскать по Интернету, чтобы отыскать обозревателей рыночных тенденций, которые возбужденно предвещают, что через 10 лет нам потребуется на миллиарды и миллиарды больше исследователей данных, чем мы имеем на текущий момент.

Но что же это такое — наука о данных? В конце концов нельзя же выпускать специалистов в этой области, если не знаешь, что она собой представляет. Согласно диаграмме Венна^{2,3}, которая довольно известна в этой отрасли, наука о данных находится на пересечении:

- ◆ алгоритмических и хакерских навыков;
- ◆ знаний математики и статистики;
- ◆ профессионального опыта в предметной области.

Собираясь с самого начала написать книгу, охватывающую все три направления, я быстро пришел к выводу, что всестороннее обсуждение профессионального опыта в предметной области потребовало бы десятков тысяч страниц. Тогда я решил сосредоточиться на первых двух. Задача — помочь желающим развить свои навыки алгоритмизации, которые потребуются для того, чтобы приступить к решению задач в области науки о данных, а также почувствовать себя комфортно с математикой и статистикой, которые находятся в центре этой междисциплинарной практической сферы.

Довольно трудновыполнимая задача для книги. Развивать свои навыки алгоритмизации лучше всего решая прикладные задачи. Прочтя эту книгу, читатель получит хорошее представление о моих способах алгоритмизации прикладных задач, неко-

¹ См. <https://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century>.

² См. <http://drewconway.com/zia/2013/3/26/the-data-science-venn-diagram>.

³ Джон Венн (1834–1923) — английский логик, предложивший схематичное изображение всех возможных пересечений нескольких (часто — трех) множеств (см. https://ru.wikipedia.org/wiki/Венн,_Джон). — *Прим. пер.*

торых инструментах, которыми я пользуюсь в работе, и моем подходе к решению задач, связанных с анализом данных. Но это вовсе не означает, что мои способы, инструменты и подход являются единственно возможными. Надеюсь, что мой опыт вдохновит попробовать пойти собственным путем. Все исходные коды и данные из книги доступны на GitHub (<https://github.com/joelgrus/data-science-from-scratch>); они помогут приступить к работе.

То же самое касается и математики. Ею лучше всего заниматься, решая математические задачи. Данная книга, разумеется, не является руководством по математике, и мы не собираемся, по большей части, заниматься ею. Однако действительность такова, что заниматься наукой о данных не получится без некоторых представлений о теории вероятностей, математической статистике и линейной алгебре. Это значит, что по мере надобности мы будем уходить с головой в математические равенства, интуицию, аксиомы и мультяшные версии глобальных математических идей. Надеюсь, читатель не побоится погрузиться в них вместе со мной.

По ходу изложения я также надеюсь передать ощущение, что импровизировать с данными — это увлекательное занятие, потому что, как бы это сказать, импровизировать с ними на самом деле увлекательно! В особенности, если сравнивать с такими альтернативами, как подготовка налоговой декларации или добыча угля.

С нуля

Для работы в области науки о данных разработана масса программных библиотек, вычислительных каркасов, модулей и наборов инструментов, которые эффективно имплементируют⁴ наиболее (нередко, и наименее) общие алгоритмы и технические решения, применяемые в науке о данных. Тот, кто станет исследователем данных, несомненно, будет досконально знать научно-вычислительную библиотеку NumPy, библиотеку машинного обучения `scikit-learn`, библиотеку для анализа данных `pandas` и множество других. Они прекрасно подходят для решения задач, связанных с наукой о данных. Но они также способствуют тому, чтобы начать решать задачи в области науки о данных, фактически не понимая ее.

В этой книге мы станем двигаться в сторону науки о данных, стартовав с нулевой отметки, а именно займемся разработкой инструментов и имплементацией⁴ алгоритмов вручную для того, чтобы разбираться в них лучше. Я вложил немало своего умственного труда в создание ясных, хорошо задокументированных и читаемых имплементаций алгоритмов и примеров. В большинстве случаев инструменты, которые мы станем конструировать, будут иметь не практический, а разъясняющий характер. Они хорошо работают с игрушечными наборами данных, но не справляются с данными "веб-масштаба".

⁴ Под имплементацией подразумевается воплощение дизайна в структурах данных, классах, объектах, функциях, интерфейсах и т. д. Под реализацией — материализация дизайна в готовом инструменте или законченном продукте.

Поскольку в ряде работ проводится четкое различие между фазами инженерии программно-информационного обеспечения: 1) архитектурный дизайн, 2) имплементация и 3) реализация. — *Прим. пер.*

По ходу изложения я буду отсылать читателя к библиотекам, которые подойдут для применения этих методов на более крупных наборах данных. Но мы их тут использовать не будем.

По поводу того, какой язык программирования лучше всего подходит для усвоения науки о данных, развернулась здоровая полемика. Многие настаивают на языке статистического программирования R (мы называем таких людей неправильными). Некоторые предлагают Java или Scala. Однако, по моему мнению, Python — идеальный вариант.

Он обладает несколькими особенностями, которые делают его наиболее пригодным для изучения и решения задач в области науки о данных:

- ◆ он бесплатный;
- ◆ он относительно прост в написании кода (и в особенности в понимании);
- ◆ он располагает сотнями прикладных библиотек, предназначенных для работы в области науки о данных.

Не решусь назвать Python моим предпочтительным языком программирования. Есть другие языки, которые я нахожу более удобными, продуманными либо просто интересными для программирования. И все же практически всякий раз, когда я начинаю новый проект в области науки о данных, либо, когда мне нужно быстро набросать рабочий прототип либо продемонстрировать концепции этой практической дисциплины ясным и легким для понимания способом, я всякий раз в итоге применяю Python. И поэтому в этой книге используется Python.

Эта книга не предназначена для того, чтобы научить программировать на Python (хотя я почти уверен, что, прочтя ее, этому можно немного научиться). Тем не менее я проведу интенсивный курс программирования на Python (ему будет посвящена целая глава), где будут высвечены характерные черты, которые в данном случае приобретают особую важность. Однако если знания, как программировать на Python (или о программировании вообще), отсутствуют, то читателю остается самому дополнить эту книгу чем-то вроде руководства по Python для начинающих.

В последующих частях нашего введения в науку о данных будет принят такой же подход — углубляться в детали там, где они оказываются решающими или показательными. В других ситуациях на читателя возлагается задача домысливать детали самому или заглядывать в Википедию.

За годы работы в отрасли я подготовил ряд специалистов в области науки о данных. Хотя не все из них стали меняющими мир супер-мега-рок-звездами в области анализа данных, тем не менее я их всех выпустил более подготовленными специалистами, чем они были до этого. И я все больше убеждаюсь в том, что любой, у кого есть некоторые математические способности вкупе с определенным набором навыков в программировании, располагает всем необходимым для решения задач в области науки о данных. Все, чего она требует, — это лишь пытливый ум, готовность усердно трудиться и наличие данного пособия. Отсюда и эта книга.